


Analisis de la base de datos 202 de la paqueteria tsld de R

HERNANDEZ DAMIAN JOSUE VALDEMAR

Analisis descriptivo

La serie de tiempo describe el Número de pasajeros de autobús entre semana en Iowa City (promedios mensuales), de septiembre de 1971 a diciembre de 1982 y posee 148 observaciones. Podemos ver que no existe ningun valor faltante en la serie de tiempo utilizando `any(is.na())` y el resultado es `FALSE`, por lo tanto no es necesario imputar.

```
## [1] FALSE
```





Podemos observar que la varianza no es constante, ya que aumenta conforme pasan los años. Además, se identifica una tendencia creciente no lineal, que se curva hacia arriba a medida que avanza el tiempo. Por último, se aprecia un comportamiento estacional cada año, es decir, con un período de 12.

Para respaldar la idea de que existe un comportamiento estacional con un período de 12, utilizaremos la funcion `isSeasonal()` para probar si una serie de tiempo tienen estacionalidad significativa utilizando el test `kruskal-wallis` y considerando la frecuencia de 12

```
## [1] TRUE
```

Como el resultado es `TRUE`, es decir, **existe un comportamiento estacional con un período de 12**.

Ahora veamos el diagrama de caja por periodo y Seasonal Plot de la serie:



El diagrama de caja por periodo permite analizar el comportamiento estacional de la serie a lo largo de un ciclo completo, en este caso un año. En el gráfico se observa que los valores presentan una variación significativa entre los distintos periodos, lo que evidencia la presencia de un patrón estacional marcado.

Durante los primeros meses (periodos 1 a 3), los valores tienden a ser más altos, con medianas elevadas, lo que indica una fase de incremento. Posteriormente, entre los periodos 5 a 8, los valores disminuyen de manera notable, alcanzando los niveles más bajos del año; esto sugiere una fase de descenso o mínima actividad. Finalmente, en los periodos 9 a 12, los valores aumentan nuevamente, indicando el inicio de un nuevo ciclo ascendente.

Finalmente el análisis confirma la **existencia de una componente estacional anual**.

El Seasonal Plot muestra un patrón recurrente a lo largo del año, lo notamos por valores altos en los primeros meses (enero-marzo), un descenso sostenido hasta mediados del año (junio-agosto) y una recuperación hacia el final del periodo (septiembre-diciembre). Este comportamiento se repite de manera consistente entre todos los años de la serie, lo que confirma la **presencia de una componente estacional anual bien definida**. Además, se observa una **tendencia creciente en el nivel general de la serie**, ya que los valores de los años más recientes son mayores en comparación con los de los primeros años del periodo analizado.

Para verificar que la varianza no es constante, utilizaremos la prueba de **Breusch-Pagan**: Esta prueba evalúa heterocedasticidad en los residuos de un modelo de regresión lineal.

La hipótesis son:

H_0 : la varianza de los residuos es constante (homocedasticidad)

H_1 : la varianza de los residuos no es constante (heterocedasticidad)

Hay que recordar que si el **p-value** < **0.05**, entonces rechazamos H_0 a un nivel de confianza de 95%

```
##
## studentized Breusch-Pagan test
##
## data: lm(Xt ~ time)
## BP = 14.648, df = 1, p-value = 0.0001296
```

El p -value = 0.0001296 indica que se rechaza la hipótesis nula, es decir que **hay evidencia estadística para decir que la varianza es no constante**.

También realizamos la prueba **Non-constant Variance**: Similar a la anterior prueba, también detecta heterocedasticidad en un modelo de regresión lineal. Contrasta si la varianza de los residuos cambia en función de la variable explicativa más importante del modelo. Las hipótesis son:

H_0 : existe homocedasticidad en la varianza de los residuos (varianza constante).


H_1 : no existe homocedasticidad en la varianza de los residuos (varianza no es constante)

```
## Non-constant Variance Score Test
## Variance formula: ~ fitted.values
## Chisquare = 11.13741, Df = 1, p = 0.00084604
```

En este caso, $p - value = 0.00084604$, es decir que rechazamos la hipótesis nula. Entonces hay **evidencia estadística para decir que la varianza es no constante**.

Sería necesario aplicar una transformación a la serie para estabilizarla o utilizar un suavizamiento con un efecto multiplicativo.

Por último observemos el ACF y PACF:




Se puede observar en la gráfica de la función de autocorrelación (ACF) que existe una fuerte correlación de los datos, especialmente cada 12 lags pues se observan los picos más grandes, lo anterior es normal porque sabemos que hay estacionalidad anual. Se observa un patrón decreciente, pues existe autocorrelaciones altas en los primeros rezagos, que van disminuyendo gradualmente.

En la gráfica de la función de autocorrelación parcial (PACF), notamos que existe un pico alto y significativo, esto sugiere un término AR(1) con el componente estacional anual, es decir un ARIMA(1,12,0) tal vez. Muchos de los valores quedan dentro del intervalo de confianza, por lo que no son significativos; pero hay picos en varios valores que salen de la banda e indican efectos estacionales.

Como conclusión, la serie puede tener una diferencia simple (ya que no hay una fuerte caída exponencial) y hay una diferencia estacional intrínseca.

Ajuste ARIMA, SAMIRA u otro

Anteriormente vimos que la varianza no es constante por lo que es necesario aplicar una transformación para poder ajustar un modelo a la serie.



Realizamos un modelo de regresión para ver si la serie transformada ya cumple con varianza constante.


```
## Non-constant Variance Score Test
## Variance formula: ~ fitted.values
## Chisquare = 0.04829642, Df = 1, p = 0.82605
```

Obtuvimos un p-value = 0.82605 por lo tanto no rechazamos la hipótesis nula y concluimos que tenemos varianza constante.

```
##
## studentized Breusch-Pagan test
##
## data: lm(log_xt ~ time)
## BP = 0.0896, df = 1, p-value = 0.7647
```

Si realizamos la prueba de Breusch-Pagan obtenemos un p-value=0.7647 por lo que no rechazamos la hipótesis nula y volvemos a concluir que tenemos varianza constante.

Para empezar a ajustar un modelo primero vamos a aplicar una descomposición para poder ver los elementos de la serie.



```
## [1] TRUE
```

```
## Test used: Kruskal Wallis
```


```
##
```

```
## Test statistic: 109.26
```

```
## P-value: 0
```

Por lo anterior podemos observar que en efecto tiene tendencia y estacionalidad por lo que es necesario aplicar diferenciación.

Para elegir cuántas diferencias aplicar, vamos a comparar las varianzas de la serie con las diferencias y elegiremos la diferencia con menor varianza.



```
## [1] 0.006295328
```

Comparamos las varianzas de la serie con las diferencias anteriores y obtuvimos que la diferencia con menor varianza fue $\text{diff}(\text{diff}(\log_xt), 12)$, gracias a esto llegamos a que el valor de $d=1$, $D=1$ y $s=12$.

En el gráfico superior se observa que la serie transformada oscila alrededor de la media cero, sin mostrar tendencia ni patrones estacionales visibles. La varianza se mantiene estable a lo largo del tiempo, lo cual indica que las transformaciones aplicadas fueron efectivas para estabilizar tanto la media como la varianza, cumpliendo con las condiciones necesarias para ajustar un modelo ARIMA o SARIMA.

El análisis de la función de autocorrelación (ACF) muestra que las correlaciones entre los valores actuales y los valores anteriores disminuyen rápidamente y se mantienen, en su mayoría, dentro de los límites de significancia. Esto sugiere que no existe una dependencia fuerte entre los valores de distintos períodos, lo que indica que los componentes de tendencia y estacionalidad fueron eliminados adecuadamente. Por otro lado, la función de autocorrelación parcial (PACF) presenta un leve pico en el primer período y una posible pequeña señal en el duodécimo, lo que podría asociarse con la presencia de un término autorregresivo simple o estacional de bajo orden.

```
##
```

```
## Augmented Dickey-Fuller Test
```

```
##
```

```
## data: Wt
```

```
## Dickey-Fuller = -7.3838, Lag order = 4, p-value = 0.01
```

```
## alternative hypothesis: stationary
```

A partir de estas observaciones, se concluye que la serie diferenciada es estacionaria pues obtuvimos un p-value = 0.01 por lo tanto rechazamos H_0 y es apta para la estimación de modelos SARIMA con parámetros bajos. Los modelos candidatos más razonables para su evaluación son los siguientes:

Proponemos como opciones iniciales:

SARIMA(0,1,1)(0,1,1) SARIMA(1,1,0)(0,1,1) SARIMA(0,1,1)(1,1,0)

##	Modelo	Parametro	Lower	Upper
## ar1	auto.arima	ar1	0.811797407	1.024491253
## ma1	auto.arima	ma1	-0.777066762	-0.266852165
## sma1	auto.arima	sma1	-1.031431437	-0.513707247
## drift	auto.arima	drift	0.003912814	0.007098734
## ma11	SARIMA(0,1,1)(0,1,1)[12]	ma1	-0.779974424	-0.406545121
## sma11	SARIMA(0,1,1)(0,1,1)[12]	sma1	-1.018881194	-0.527257470
## ar11	SARIMA(1,1,0)(0,1,1)[12]	ar1	-0.593393157	-0.255201078
## sma12	SARIMA(1,1,0)(0,1,1)[12]	sma1	-0.979222495	-0.476644675
## ma12	SARIMA(0,1,1)(1,1,0)[12]	ma1	-0.735310328	-0.362727876
## sar1	SARIMA(0,1,1)(1,1,0)[12]	sar1	-0.597408424	-0.238735319
##	Significancia			
## ar1	Significativo			
## ma1	Significativo			
## sma1	Significativo			
## drift	Significativo			
## ma11	Significativo			
## sma11	Significativo			
## ar11	Significativo			
## sma12	Significativo			
## ma12	Significativo			
## sar1	Significativo			

Ajustamos 4 modelos, uno utilizando auto.arima que nos arrojó que el mejor modelo es ARIMA(1,0,1)(0,1,1)[12], otro candidato fue un SARIMA(0,1,1)(0,1,1)[12], otro SARIMA(1,1,0)(0,1,1)[12] y por último SARIMA(0,1,1)(1,1,0)[12]. También analizamos los intervalos de confianza de los parámetros de cada modelo para ver si son significantes o no y notamos que para todos los modelos los parámetros son significantes.


##	Modelo	AIC	BIC	logLik	LjungBox_p
## BP	auto.arima	-324.6308	-310.5294	167.3154	0.08574635
## BP1	SARIMA(0,1,1)(0,1,1)[12]	-320.3196	-311.8830	163.1598	0.16357463
## BP2	SARIMA(1,1,0)(0,1,1)[12]	-314.5770	-306.1404	160.2885	0.07989078
## BP3	SARIMA(0,1,1)(1,1,0)[12]	-307.6453	-299.2087	156.8226	0.46654646
##	Normalidad_p	BP_p			
## BP	0.190056185	0.4598285			
## BP1	0.033902964	0.3447942			
## BP2	0.079763744	0.2413178			
## BP3	0.005694408	0.6079454			

Para elegir al mejor modelo vamos a elegir al que tenga menor AIC y BIC, en este caso notamos que el que tiene menor AIC es el modelo que arrojó el auto.arima que es el SARIMA(1,0,1)(0,1,1)[12] y el que tiene menor BIC es el modelo SARIMA(0,1,1)(0,1,1). En conjunto, el modelo 1 tiene mejor ajuste general (menor AIC, mejor logLik y mejores supuestos de normalidad y homocedasticidad). El modelo 2 mejora un poco la independencia de los residuos, pero al costo de perder normalidad.

Por lo tanto nos quedamos con el primer modelo que es que nos arrojó el auto.arima que es un $ARIMA(1,0,1)(0,1,1)[12]$. Ya vimos que pasó unas pruebas de normalidad y homocedasticidad, sin embargo, vamos a realizar más pues hay unas que se fijan más en las colas, etc.


```
##
## =====
## Modelo: auto.arima
## =====
```

Correlograma Residuales – auto.arima



```
##
## Box-Ljung test
##
## data: fit$residuals
## X-squared = 19.117, df = 12, p-value = 0.08575
```

Normal Q-Q Plot



```
##
##  Anderson-Darling normality test
##
## data:  fit$residuals
## A = 0.51359, p-value = 0.1901
##
##
##  studentized Breusch-Pagan test
##
## data:  Y ~ X
## BP = 0.54631, df = 1, p-value = 0.4598
##
## Non-constant Variance Score Test
## Variance formula: ~ fitted.values
## Chisquare = 0.6508652, Df = 1, p = 0.4198

##
##  Augmented Dickey-Fuller Test
##
## data:  fit$residuals
## Dickey-Fuller = -4.4953, Lag order = 5, p-value = 0.01
## alternative hypothesis: stationary
##
## AIC: -324.6308   BIC: -310.5294   logLik: 167.3154
```

En el qqplot notamos que en el centro la mayoría de puntos se ajusta a la línea roja, en la cola de la lado

izquierdo hay puntos que se alejan más y en la cola de lado derecho están más pegados, sin embargo, se ve que si siguen una distribución normal.

En la prueba Box-Ljung test obtuvimos que el $p\text{-value} = 0.085 > 0.05$ por lo tanto no rechazamos H_0 y se concluye que los residuales se comportan como ruido blanco ya que no hay autocorrelación significativa.

En la prueba de Anderson-Darling obtuvimos que el $p\text{-value} = 0.1901 > 0.05$ por lo tanto no rechazamos H_0 y concluimos que los residuales se distribuyen normal.

En la prueba de Breusch-Pagan y NCV test obtuvimos que ambos $p\text{-values}$ (0.4598 y 0.4198) > 0.05 por lo tanto no hay evidencia de heterocedasticidad y asumimos que tenemos varianza constante.

En la prueba ADF test obtuvimos que $p\text{-value} = 0.01 < 0.05$ por lo tanto rechazamos H_0 y concluimos que los residuos son estacionarios.

En el correlograma de los residuos, se observa que las autocorrelaciones y autocorrelaciones parciales se encuentran dentro de los límites de confianza, sin patrones sistemáticos aparentes. Esto indica que los residuos se comportan como un proceso de ruido blanco, cumpliendo con el supuesto de independencia. En consecuencia, se puede concluir que el modelo ajusta adecuadamente la estructura temporal de la serie y no deja información relevante sin modelar.

Concluimos que el mejor modelo que se ajusta a la serie es $\text{ARIMA}(1,0,1)(0,1,1)[12]$.

Pronósticos

Para esta parte de predicción primero definamos nuestro conjunto de entrenamiento el cual serán todos los datos menos el ultimo año, para posteriormente compararlas predicciones de nuestro modelo y ver si son adecuadas


Para ello usemos como referencia los valores de

- RMSE es el error cuadrático medio en raíz
- MSE es el error cuadrático medio
- MAE es el error absoluto medio
- Y el MAPE es el porcentaje de error promedio

##	MAE	RMSE	MSE	MAPE
## 1	0.08453992	0.08934693	0.007982873	0.9332052

Los cuales observamos que son valores pequeños por lo que podríamos decir que nuestro modelo es adecuado para predecir y por último viéndolo de manera gráfica, considerando intervalos de 95%

Validación: pronóstico del último año con intervalos de confianza (95%)



Por lo tanto, usemos nuestro modelo para predecir un año mas de los datos que tenemos.

Pronóstico para el proximo año (escala original)

