

T1-Exploración y Bondad de Ajuste de Distribuciones en Datos de Riesgo

Hernandez Damian Josue Valdemar

Base de datos: Indice S&P 500 de 2019-01-01 al 2024-12-31

Se escogio el S&P 500, porque el índice Standard & Poor's 500 Index (S&P 500), es uno de los índices bursátiles más importantes de Estados Unidos. Al S&P 500 se le considera el índice más representativo de la situación real del mercado. El índice se basa en la capitalización bursátil de 500 grandes empresas que poseen acciones que cotizan en las bolsas NYSE o NASDAQ, y captura aproximadamente el 80 % de toda la capitalización de mercado en Estados Unidos.

Como es un índice muy importante, es necesario conocer que tan riesgoso es para invertir. Puede haber un riesgo de mercado si el mercado bursatil cae como en la pandemia, tambien existe posibilidad de riesgo de volatilidad porque el índice puede fluctuar debido a ciclos economicos y eventos inesperados.

Se trabajara con los rendimientos diarios continuos del indice S&P 500 de 5 años, que se calculan como $\log(\frac{P_t}{P_{t-1}})$. Los datos los vamos a obtener por Yahoo Finance.

```
## [1] "GSPC"
```


Analisis de graficas

Se exploraran el histograma de los rendimientos continuos y el Boxplot.


Notamos en el histograma que existe una mayor concentración de los datos alrededor de los valores -0.5 y 0.5, lo que indica que la mayoría de los rendimientos se acumulan cerca del centro. Sin embargo, también se observan valores extremos hacia los lados del histograma, lo que significa que la distribución presenta colas más largas, es decir posibles eventos extremos o atípicos.

En el Boxplot, se aprecia que dentro de la caja la mediana se encuentra cercana al 0, lo cual coincide con la concentración central observada en el histograma y se observan muchos valores fuera de los bigotes (outliers), por lo que puede indicar que los datos tienen una distribución con colas pesadas.

Histograma de rendimientos del S&P 500




Boxplot de rendimientos del S&P 500



Con lo anterior, es importante buscar distribuciones que este definia en todos los reales, porque los rendimientos financieros pueden ser pérdidas (negativos) o ganancias (positivos). Para empezar la Normal, la t-Student y la Laplace (doble exponencial) están definidas en todo $\mathbb{R}$.

La distribución normal modela datos concentrados alrededor de la media (como lo mostradado en el Boxplot) y tiene colas delgadas. La t-Student es simetrica, centrada en 0 y puede tener colas más pesadas que la normal para explicar los valores extremos. La laplace tambien es simetrica, con media 0 y tiene colas mas pesada que la normal.

Cullen and Frey graph




```
## summary statistics
## -----
## min: -0.1276522   max:  0.08968323
## median:  0.0009236429
## mean:  0.0005675286
## estimated sd:  0.0127382
## estimated skewness:  -0.8540068
## estimated kurtosis:  18.2591
```

Ahora graficamos Cullen & Frey, en esta observamos que la mediana (0.00092) y media (0.00057) están muy cercanas a cero, entonces los rendimientos tienen un comportamiento centrado, sin sesgo fuerte hacia ganancias o pérdidas.

El skewness (-0.85) es negativo y significa que la cola izquierda es más pesada que la derecha, es decir, las pérdidas extremas son más probables que las ganancias extremas. La kurtosis (18.26) es muy alta en comparación con una normal (kurtosis aproximada de 3), entonces implica colas muy pesadas y una concentración fuerte de datos alrededor de la media.

Con skewness negativo y kurtosis muy alto, los datos son consistentes con distribuciones de colas pesadas, en esta ocasión tomaremos la t-Student con pocos grados de libertad o Laplace. Además consideramos la normal para ver si se ajusta.



Ya graficamos el QQ-plot, este compara los cuantiles de los datos con los cuantiles de una distribución teorica.

En el caso de la normal, los puntos se alinean en el centro, pero se desvian fuertemente en las colas hacia arriba y abajo, por lo que la distribución normal tiene cola más delgada que los datos.

La t-Student tiene mejor el ajuste porque los puntos siguen la recta en el centro y gran parte de las colas, solo en extremos más lejanos se observa ligera desviacion, entonces la t-Student modela mejor las colas pesada de los datos.

La Laplace tiene un buen ajuste en el centro, pero en las colas tiene cierta desviación, esto se debe que la Laplace tiene colas más pesadas que la t-Students.

Pruebas de bondas de ajuste con p-values y AIC

Ahora hay que estimar los parametros, realizar pruebas de bondas de ajuste y AIC.

Para estimar los parametros de la normal se uso la función `fitdist` para ajustar una normal a los datos por maxima verosimilitud. Para la t-Student fijamos los grados de libertad en `df=3` para colas pesadas y tambien usamos `fitdistr` para ajustar la distribucion t a los datos.

Como no hay función en R para ajustar Laplace con `fitdist`, entonces se estimo el parametro de localicación como la mediana de los datos y el parametro de escaa se estimo como el promedio de las desviaciones absolutas respecto a la mediana.

Para evaluar cada modelo, usaremos el **AIC (Akaike Information Criterion)** que se usa para comparar modelos estadísics y elegerir cual se ajusta mejor. Un AIC mas bajo indica un mejor modelo, porque logra un buen ajuste sin demasiada complejidad.

El **test de Kolmogorov-Smirnov (KS)** compara la distribución de tus datos con una distribución teórica. La Hipótesis nula: Los datos siguen la distribución teórica vs. Hipótesis alternativa: Los datos no siguen la distribución teórica. Interpretación del p-value:

Si $p\text{-value} > 0.05$ No hay evidencia para rechazar el hipotesis nula, los datos pueden seguir a distribución.

Si $p < 0.05$ entonces rechazmos la hipotesis nula y los datos no siguen la distribucion.

El **test de Anderson-Darling (AD)** también verifica si los datos siguen una distribución teórica, pero es más sensible a las colas de la distribución, donde la Hipótesis nula: Los datos siguen la distribución

Si $p > 0.05$ entonces no se rechaza la hipótesis nula, es decir es un buen ajuste y

Si $p < 0.05$ entonces rechazamos la hipótesis nula, es decir es un mal ajuste.

La prueba de **Cramér-von Mises (CvM)** es muy parecida a la de Kolmogorov-Smirnov (KS) y la de Anderson-Darling (AD). Tenemos de hipótesis:

Hipótesis nula: los datos provienen de la distribución especificada vs. Hipótesis alternativa: los datos no provienen de esa distribución.

Si $p\text{-value} > 0.05$, entonces no se rechaza la hipótesis nula, es decir los datos son compatibles con la distribución propuesta

Si el $p\text{-value} < 0.05$, entonces se rechaza la hipótesis nula que indica que la distribución propuesta no describe bien los datos.

DISTRIBUCION NORMAL:

Media: 0.0005675286

Desviación estándar: 0.01273398

AIC: -8876.741

KS p-value: 1.096757e-12

AD p-value: 3.97878e-07

CvM p-value: 0

DISTRIBUCION t-Student (df = 3):

Media (location): 0.001062692

Escala (sd): 0.007515903

AIC: -9386.64

KS p-value: 0.7682517

AD p-value: 0.3919435

CvM p-value: 0.5858502

DISTRIBUCION Laplace (estimación manual):

Location: 0.0009236429

Scale: 0.008280957

AIC: -9347.559

KS p-value: 0.2950262

AD p-value: 0.2217466

CvM p-value: 0.5663874

En resumen lo obtenido es:

Distribucion	parametros	p-value KS	p-value AD	p-value CvM	AIC
Normal	$\mu = 0.0005675$, $\sigma = 0.01273$	$1.096757e - 12$	$3.7e - 24$	0	-8876.74
t-Student	$t = 3$	0.7682517	$3.7e - 24$	0.5858502	-9386.64
Laplace	$\mu = 0.00092364$ (localización), $b =$ 0.0082809 (escala)	0.2950262	$3.7e - 24$	0.5663874	-9347.56

Notamos que el AIC de la t-student es el más pequeño, esto indica que es el modelo que mejor se ajusta al modelo. Además que su p-value de KS es mayor a 0.05, entonces no rechazamos la hipótesis nula y los datos si podrían venir de una t-Student con $df=3$.

El modelo Laplace tiene un AIC no es tan grande y no tan pequeño a comparación de los otros modelos, además que también el p-value de KS es mayor a 0.05 entonces no rechazamos la hipótesis nula y los datos si podrían ajustarse a esa distribución.

En la prueba CvM, la t-student y la Laplace, su p-value es mayor a 0.05, es decir que los datos son compatibles con la distribución propuesta.

En el modelo de la Normal, el p-value en las tres pruebas de KS , AD y CvM es menor a 0.05, entonces rechazamos la hipótesis nula de que los datos se pueden ajustar de una normal y su AIC es el más grande, esto refleja que es un peor ajuste a comparación con los otros modelos.

Notamos que en los 3 modelos, el p-value de AD son menores a 0.05, entonces esto quiere decir que todavía hay información de las colas extremas que estos modelos no pueden rescatar.

Conclusion

Las hipótesis iniciales planteaba que los datos podrían ajustarse a distribuciones como la Normal, t-Student o Laplace, porque considere la posible presencia de colas pesadas y valores de los rendimientos reales y positivo.


Los resultados muestran que la t-Student ($df=3$) es el modelo que mejor se ajusta, con AIC más bajo y p-value del KS, de AD y CvM son menores a 0.05, confirmando que los datos podrían provenir de esta distribución. La Laplace también es razonable, aunque con ajuste ligeramente inferior. En cambio, la Normal no es adecuada, pues sus p-values de KS , AD y CvM son menores a 0.05 y su AIC es el más alto.

Sin embargo, los p-values del test AD en todos los modelos < 0.05 indican que ninguno captura completamente las colas extremas, sugiriendo que podría ser necesario considerar distribuciones con colas más pesadas para un ajuste completo.

Al graficar la función de distribución empírica y las funciones de distribución estimadas, así como la densidad estimada sobre el histograma, se observa que la t-Student y la Laplace se ajustan mejor que la Normal, confirmando visualmente los resultados estadísticos.

En resumen, las hipótesis fueron parcialmente congruentes: la t-Student y Laplace reflejan correctamente la tendencia general, pero las colas extremas requieren modelos más específicos. La normal no refleja el comportamiento de los datos, entonces lo mejor es buscar más distribuciones que se ajusten mejor.

Función de distribución empírica vs ajustes



Histograma con densidades ajustadas

